

卒業論文

RNN における生物学的学習則の比較

17A1501 伊藤優也

指導教員 山口裕 助教

2022 年 2 月

福岡工業大学情報工学部情報工学科

目次

第 1 章	序論	1
1.1	背景	1
1.2	RNN	1
1.3	本研究の目的	1
1.4	論文の構成	2
第 2 章	実験モデル	3
2.1	ネットワークモデル	3
2.2	生物学的学習則	4
2.2.1	ヘブ学習則	4
2.2.2	時空間学習則	5
2.3	リッジ回帰	5
2.4	手法	6
第 3 章	実験結果	7
第 4 章	議論	8
4.1	ヘブ学習則に関する議論	8
4.2	時空間学習則に関する議論	8
第 5 章	結論	9
5.1	本研究の結論	9
5.2	今後の展望	9
	謝辞	10
	参考文献	11

第 1 章

序論

本論文は、Recurrent Neural Network (RNN) を用いて複数の生物学的学習則をタスクに対する性能で比較し、それぞれの生物学的学習則の役割を考察するものである。この章では、生物学的学習則の研究に関する背景、RNN の説明と採用理由、本研究の目的、本論文の構成について記す。

1.1 背景

人間の記憶機能に関して重要な役割を担っていると考えられている脳の海馬の研究は古くから行われている。近年、その海馬の機能に関連していると考えられているシナプス学習則についての研究が盛んに行われており、生物学的学習則にはパターン補完やパターン分離の機能があると考えられている [1]。しかし、現状この生物学的学習則の 1 つである時空間学習則により学習したモデルを用いて具体的な情報処理タスクを解く研究はあまり行われていない。そこで、情報処理タスクを与えた RNN を用いて複数の生物学的学習則の特徴を比較し、それぞれの学習における役割を考察した。

1.2 RNN

RNN は時系列データを 1 つの入力データ群として扱うニューラルネットワークであり、過去のデータが現在、未来に影響を与える再帰的なニューラルネットワークである。このようなネットワーク構造は脳の情報処理機能に酷似しているため、RNN を本研究のネットワークモデルに用いた。

1.3 本研究の目的

本研究では、生物学的学習を行っていない RNN、ヘブ学習を行った RNN、時空間学習を行った RNN について、それぞれタスクに対する性能を比較する。これらの結果から、それぞれの学習における役割を考察するのが本研究の目的である。

1.4 論文の構成

本論文の構成を章ごとに説明する．第 2 章では，実験モデルに用いるネットワークモデルの説明を記した後，本研究で比較する生物学的学習則の説明と出力層での教師あり学習であるリッジ回帰の説明を記し，最後に実験の手法を記す．第 3 章では，行った実験の結果を示し，第 4 章では，結果に対する議論について記す．第 5 章では，本研究の結論を記した後，今後の展望について記す．

第 2 章

実験モデル

この章では、本実験で用いるネットワークモデルの説明を記した後、本研究で比較する生物学的学習則の説明と出力層での教師あり学習であるリッジ回帰の説明を記す。最後に本実験の手法を記す。

2.1 ネットワークモデル

本実験で用いるネットワークは、前の時刻 $t-1$ からの接続を $1-\alpha$ 倍、現時刻 t の入力を α 倍する Leaky ユニットをもった RNN である。 α はリーク率と呼ばれ、 α が小さいほど、時間変化が遅くなる。中間層の式は式 (2.1) で得られる。

$$\mathbf{h}(t) = (1 - \alpha)\mathbf{h}(t - 1) + \alpha[W^{in}\mathbf{x}(t) + Wf(\mathbf{h}(t - 1))] \quad (2.1)$$

W^{in} は入力層の重み行列、 $\mathbf{x}(t)$ は時刻 t の入力、 W は中間層の重み行列、 $f(\cdot)$ は活性化関数の \tanh 関数である。出力層の式は式 (2.1) を用いて、式 (2.2) で得られる。

$$\mathbf{y}(t) = W^{out}f(\mathbf{h}(t)) \quad (2.2)$$

W^{out} は出力層の重み行列である。さらに、ネットワークのモデルとしてリザーバーコンピューティングを用いる。これは、時系列情報処理に適した機械学習の枠組みの 1 つで、RNN のモデルの一種である。リザーバーコンピューティングは、結合重みを固定した RNN によって、入力データを非線形変換し、出力部の結合重みのみを調整して学習を行うモデルであり、リザーバーと出力層から構成される。出力部の結合重みのみを調整して学習することから、簡便な学習が可能であるため、本実験のモデルとして採用した。本実験におけるリザーバーの状態発展の概略図を図 2.1 に示し、ネットワークモデルの概略図を図 2.2 に示す。




図 2.1. リザーバーの状態発展の概略図

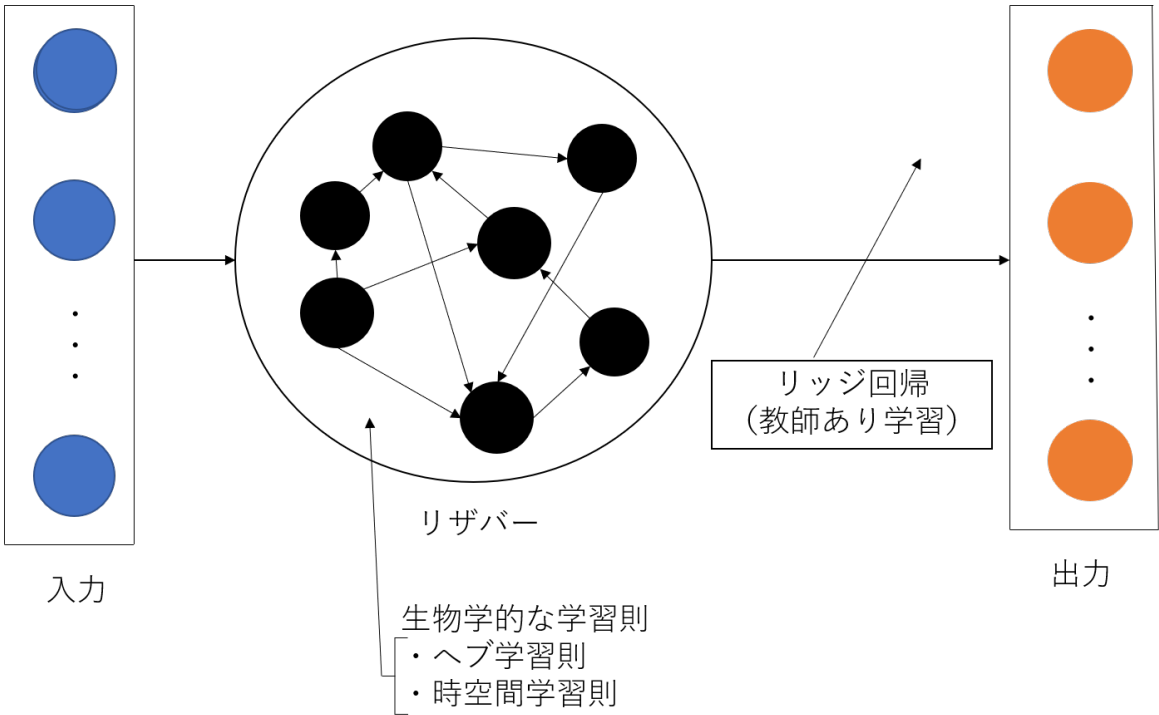


図 2.2. ネットワークモデルの概略図

2.2 生物学的学習則

2.2.1 ヘブ学習則

ヘブ学習則 [2] は、入力ニューロンと出力ニューロンの間のシナプス結合が、両方のニューロンが発火するたびに変更される学習則である。この学習則におけるシナプス結合の強さの変

化量は式 (2.3) で得られる.

$$\Delta W_{ij}(t_n) = W_{ij}(t_{n+1}) - W_{ij}(t_n) = \eta Y_j(t) X_i(t) \quad (2.3)$$

η は学習係数, $Y_j(t)$ は時刻 t における出力, $X_i(t)$ は時刻 t における入力である.

2.2.2 時空間学習則

時空間学習則 [2] は, 入力ニューロン間の発火時間の同期性に依存してシナプス結合が変更される学習則であり, この学習則の性質を表した係数のことを一致係数という. 一致係数 $I_{ij}(t_n)$ は, i 番目の入力ニューロンのスパイクが時刻 t_n で j 番目の出力ニューロンに到達したときの他のニューロンの協調活動の強さに依存し, 式 (2.4) で定義される.

$$I_{ij}(t_n) = w_{ij}(t_n) x_i(t_n) \sum_{k=1, k \neq i}^N w_{kj}(t_n) x_k(t_n) \quad (2.4)$$

$w_{ij}(t_n)$ は時刻 t_n における i 行 j 列目の重み, $x_i(t_n)$ は時刻 t_n における i 番目の入力である. 時空間学習則によるシナプス結合の強さの変化量は式 (2.4) を用いて, 式 (2.5) で得られる.

$$\Delta W_{ij}(t_n) = \begin{cases} \eta g(I_{ij}(t_n) - \theta_1) & (I_{ij}(t_n) \geq \theta_1) \\ 0 & (\theta_1 > I_{ij}(t_n) > \theta_2) \\ \eta g(I_{ij}(t_n) - \theta_2) & (I_{ij}(t_n) \leq \theta_2) \end{cases} \quad (2.5)$$

$g(\cdot)$ は活性化関数のシグモイド関数, θ_1 と θ_2 は閾値である.

2.3 リッジ回帰

最小二乗法による二乗和誤差の総和に学習パラメータの二乗和を正規化項として加えた正規化を L_2 正規化といい, この場合の最適な重み W^{out} を求める回帰をリッジ回帰という [3]. この学習において最小化すべきコスト関数 E_{LR} は式 (2.6) で得られる.

$$E_{LR} = \frac{1}{2} \|D - W^{out} H\|^2 + \frac{\beta}{2} \|W^{out}\|^2 \quad (2.6)$$

$\beta > 0$ は正規化項の大きさを調節する正規化パラメータであり, D は正解データ行列, H は入力データ行列である. このとき, 誤差が最小化された重み \hat{W}^{out} は式 (2.7) で得られる.

$$\hat{W}^{out} = DH^T (HH^T + \beta I)^{-1} \quad (2.7)$$

I は単位行列を表す. これらの式は β の値に応じて, 正規化の強さが変化する.

2.4 手法

本実験では、MNIST の画像データを情報処理タスクとして、実験を行った。用いる画像データ 1 枚のサイズは 28×28 である。バッチサイズを 64 に設定して、データセットを入力し、画像 60,000 枚を訓練データ、10,000 枚をテストデータとした。ネットワーク層は以下の 3 つの層に分ける。

- 入力層 (MNIST データセット)
- 中間層 (リザバー)
- 出力層 (全結合層)

このネットワーク層の内、中間層のリザバーにそれぞれの生物学的学習則を適用して学習を行い、出力層に教師あり学習のリッジ回帰を適用することで、評価を行った。なお、リッジ回帰はオフライン学習であるため、バッチデータを 1 つにまとめたデータを用いて、リッジ回帰の処理を行った。リザバー内での実験の条件を以下に示す。

- 生物学的学習なし
- ヘブ学習
- 時空間学習

実験の流れを以下に示す。

- データセットを使い切るまで、以下の処理を繰り返した。
 1. バッチサイズ分のデータを入力層に入力。
 2. 入力されたデータを中間層に送り、リザバー内で教師なし学習。
- バッチデータを 1 つにまとめたデータを用いて、以下の処理を行った。
 1. 学習後のデータを全結合層に送り、リッジ回帰によって重みを最適化。
 2. 重みを最適化したデータを用いて、損失と正解率を計算。

以上のような流れで実験を行った。

第 3 章

実験結果

この章では，テストデータにおける実験結果を示す．テストデータにおけるエポックごとの正解率を図 3.1 に示す．




図 3.1. テストデータにおけるエポックごとの正解率

テストデータにおける条件ごとの正解率を表 3.1 に示す．

表 3.1. テストデータにおける条件ごとの正解率

エポック数	生物学的学習なし	ヘブ学習	時空間学習
1	0.7682	0.7680	0.7626
2	0.7683	0.7710	0.7631
3	0.7682	0.1092	0.7630
4	0.7682	0.1001	0.7632
5	0.7682	0.1118	0.7629

第 4 章

議論

この章では、第 3 章で示した結果に対して、それぞれの生物学的学習則に関する議論について記す。

4.1 ヘブ学習則に関する議論

ヘブ学習を行ったモデルの正解率は、3 エポック以降大幅に低下した。ヘブ学習則により性能が低下した原因の可能性として、学習後のネットワークに初期値鋭敏性をもつカオスが発生した可能性が挙げられる。

4.2 時空間学習則に関する議論

時空間学習を行ったモデルの正解率は、生物学的学習を行わなかった場合と比べて、ほぼ正解率が変わらなかった。このことから、時空間学習では、シナプス結合の強さが学習によってあまり変わっていない可能性がある。

第 5 章

結論

この章では、第 4 章での議論に対する結論を記した後、今後の展望について記す。

5.1 本研究の結論

本研究における実験では生物学的学習則の役割を考察するために必要な結果を得ることができなかった。したがって、ヘブ学習と時空間学習が性能を向上させるように機能しなかった要因を突き止め、改善する必要がある。ヘブ学習を行ったモデルでは、結合強度を全体的に調整することにより性能が改善することが可能性の 1 つとして考えられる。時空間学習を行ったモデルでは、閾値の調整をすることにより性能が改善することが可能性の 1 つとして考えられる。

5.2 今後の展望

今後の展望として、本研究で発生したそれぞれの生物学的学習則に関する問題の改善と、生物学的学習則の機能である、パターン補完やパターン分離を確認する方法を模索することが挙げられる。

謝辞

本研究を行うにあたって、適切なご指導をしてくださった福岡工業大学情報工学部情報工学科 山口裕助教に対し、深く御礼申し上げます。

山口研究室のメンバーの方々には研究活動を行うにあたり、様々なご助言をしていただいたことに感謝の意を表します。

参考文献

- [1] Tsukada H and Tsukada M (2021) Comparison of Pattern Discrimination Mechanisms of Hebbian and Spatiotemporal Learning Rules in Self-Organization. *Front. Syst. Neurosci.* 15:624353.
- [2] Tsukada, M., and Pan, X. (2005). The spatiotemporal learning rule and its efficiency in separating spatiotemporal patterns. *Biol. Cybern.* 92, 139 – 146.
- [3] 田中剛平, 中根了昌, 廣瀬明, リザバーコンピューティング—時系列パターン認識のための高速機械学習の理論とハードウェア, 森北出版株式会社, 2021.