

RNNにおける生物学的学習則の比較

山口研究室

17A1501 伊藤優也



目次

- ・ 背景
- ・ 目的
- ・ RNN
- ・ 手法
- ・ 生物学的学習則
- ・ 出力層の教師あり学習
- ・ 結果
- ・ 考察と今後の展望



背景

- ・ 脳の記憶機能に関して重要な役割を担っていると考えられている海馬の研究は古くから行われている。
- ・ 近年、その海馬の機能に関連していると考えられている生物学的学習則についての研究が盛んに行われている。
- ・ 生物学的学習則にはパターン補完やパターン分離能力があると考えられている。

目的

- ・ 生物学的学習則の1つである時空間学習則を用いて具体的な情報処理タスクを解く研究はあまり行われていない。
- ・ リカレントニューラルネットワーク（RNN）を用いて生物学的学習則を比較することで新たな知見が得られるのではないか。
- ・ RNNのモデルの内、リザーバーで生物学的な教師なし学習を行った。

RNN

- ・一般的なニューラルネットワークは1つのベクトル x を1つの入力データとして扱うが、RNNは時系列データ($x(1), \dots, x(t), \dots, x(T)$)が1つの入力データ群となる。
- ・ RNNとは、過去のデータが現在、未来に影響を与える再帰的なニューラルネットワークである。
 - このネットワーク構造は脳の情報処理機能に似ているため、RNNを本研究のネットワークに用いた。

RNN

前の時刻から接続を $(1-\alpha)$ 倍、現時刻の入力を α 倍する
LeakyユニットをもったRNNを用いる
 α はリーク率で、 α が小さいほど時間変化が遅くなる

中間層の式は次式で与えられる：

$$\mathbf{h}(t) = (1 - \alpha)\mathbf{h}(t - 1) + \alpha \left(W^{in} \mathbf{x}(t) + Wf(\mathbf{h}(t - 1)) \right)$$

出力層の式は次式で与えられる：

$$\mathbf{y}(t) = f(W^{out} \mathbf{h}(t))$$

$f(\cdot)$ は tanh 関数

手法

[用いるデータセット]

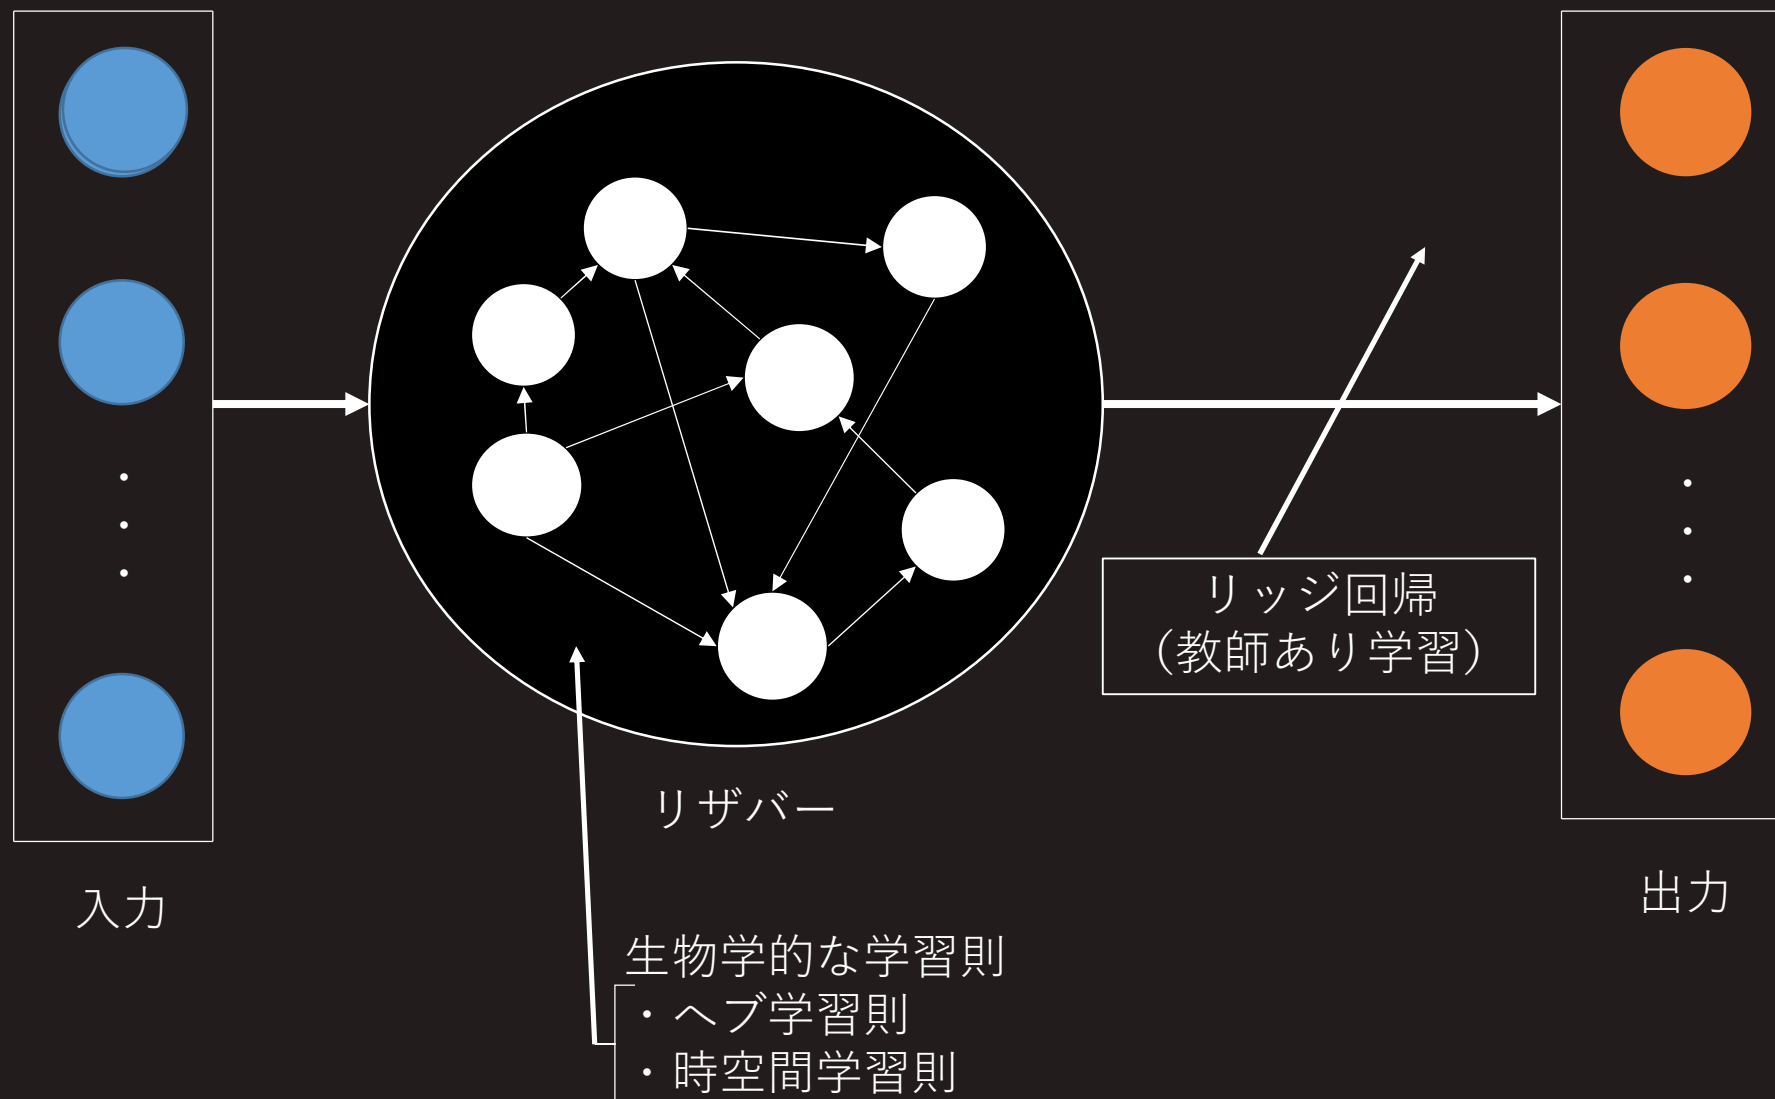
- ・ MNISTの画像データ（ 28×28 ）の判別を情報処理タスクとして、実験を行った。
- ・ バッチサイズを64にして、データセットを入力した。
- ・ 画像60,000枚を訓練データ、10,000枚をテストデータとした。

ネットワークは以下の3つの層に分ける

- ・ 入力層（MNISTデータセット）
- ・ 中間層（リザバー）
- ・ 出力層（全結合層）

手法

構築するネットワークモデルの概略図



生物学的学習則（ヘブ学習則）

引用：Tsukada, M., and Pan, X. (2005). The spatiotemporal learning rule and its efficiency in separating spatiotemporal patterns. Biol. Cybern. 92, 139–146.

[ヘブ学習則のアルゴリズム]

ヘブ学習則は、入力ニューロンと出力ニューロンの間のシナプス結合が、両方のニューロンが発火するたびに変更される学習則である。

ヘブ学習則によるシナプス結合の強さの変化量は次式で与えられる：

$$\Delta W_{ij}(t_n) = W_{ij}(t_{n+1}) - W_{ij}(t_n) = \eta Y_j(t) X_i(t)$$

生物学的学習則（時空間学習則）

[時空間学習則のアルゴリズム]

時空間学習則は、入力ニューロン間の発火時間の同期性に依存してシナプス結合が変更される学習則である。

一致係数 $I_{ij}(t_n)$ は、 i 番目の入力ニューロンのスパイクがある時刻で j 番目の出力ニューロンに到達したときの他の入力ニューロンの協調活動の強さに依存し、次のように定義される：

$$I_{ij}(t_n) = w_{ij}(t_n)x_i(t_n) \sum_{k=1, k \neq i}^N w_{kj}(t_n)x_k(t_n)$$

時空間学習則によるシナプス結合の強さの変化量は $I_{ij}(t_n)$ を用いて次式で与えられる：

$$\Delta W_{ij}(t_n) = \begin{cases} \eta g(I_{ij}(t_n) - \theta_1) & (I_{ij}(t_n) \geq \theta_1) \\ 0 & (\theta_1 > I_{ij}(t_n) > \theta_2) \\ \eta g(I_{ij}(t_n) - \theta_2) & (I_{ij}(t_n) \leq \theta_2) \end{cases}$$

$g(\cdot)$ はシグモイド関数

出力層の教師あり学習

[リッジ回帰]

最小二乗法による二乗誤差の総和に学習パラメータの二乗和を正規化項として加えた正規化を L_2 正規化 といい、この場合の最適な重み W^{out} を求める回帰をリッジ回帰という。最小化すべきコスト関数を

$$E_{LR} = \frac{1}{2} \|D - W^{out}H\|^2 + \frac{\beta}{2} \|W^{out}\|^2$$

とする。 $\beta > 0$ は正規化項の大きさを調整する正規化パラメータ。 D は正解データ、 H は入力データである。

出力層の教師あり学習

[リッジ回帰の最小化問題]

このとき誤差が最小化された重みは


$$\hat{W}^{out} = DH^T(HH^T + \beta I)^{-1}$$

と求められる。 I は単位行列。

β の値に応じて正規化の強さが変化する。

以上のような教師あり学習を用いて、モデルを評価した。

結果



テストデータに対する正解率

考察と今後の展望

- ・ヘブ学習を行った実験では、3エポック以降大幅に正解率が低下した。
- ・時空間学習を行った実験では、生物学的学習を行わなかった場合と比べて、ほぼ正解率が変わらなかった。
- ヘブ学習ではカオスが発生した可能性がある。
- 時空間学習ではシナプス結合の強さが学習によってあまり変わっていない可能性がある。
- ・今後の展望として、上記2点の改善と、パターン補完、パターン分離の能力を確認する方法の模索が挙げられる。